医療系データサイエンス教育ワークショップ2023

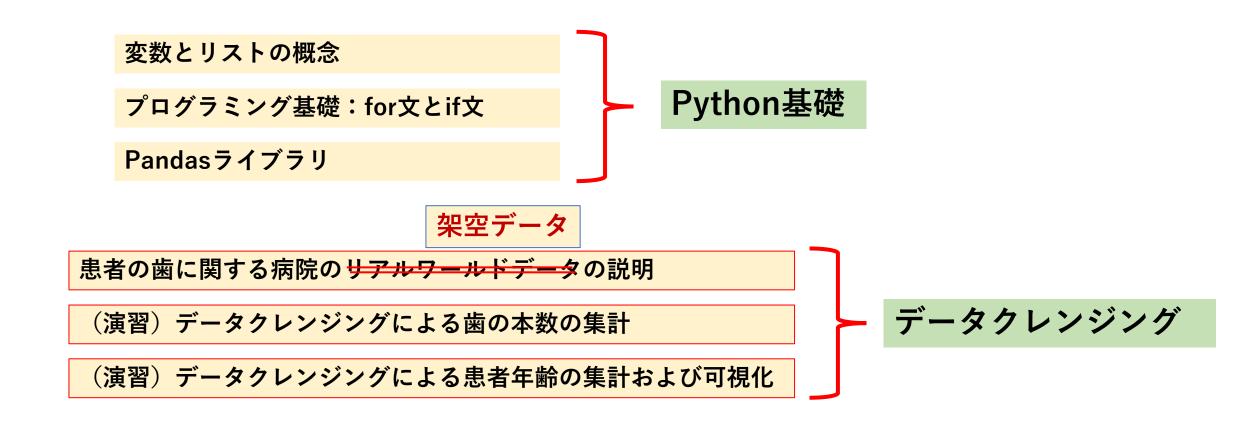
医療とAI・ビッグデータ入門演習内容紹介(45min/コマ×6コマ) 2024.2.22

本スライドは、自由にお使いください。 使用した場合は、このQRコードからアンケート に回答をお願いします。



統合教育機構 曹 日丹

医療とAI・ビッグデータ入門演習内容紹介(45min/コマ×6コマ)



患者の歯に関する病院のリアルワールドデータの説明 架空データ

東京医科歯科大学**歯科診療部門**初診患者さんのリアルワールドデータを抽出しました。

絞込条件:

初診日:2018/1/1-2022/12/31

生年月日:1943/1/1-1982/12/31(2023年1月1日時点:40歳以上、81歳未満)

抽出した内容:

id: 匿名化ID

歯式と歯の状態:残存歯、喪失歯

性別:男、女

birthmonth: 生年月、初診日: 2018/1/1-2022/12/31

,一部を無作為にシャッフルして、初診時年齢を算出して、架空データ を作成し、練習用データとしました。

患者の歯に関する病院のリアルワールドデータの説明

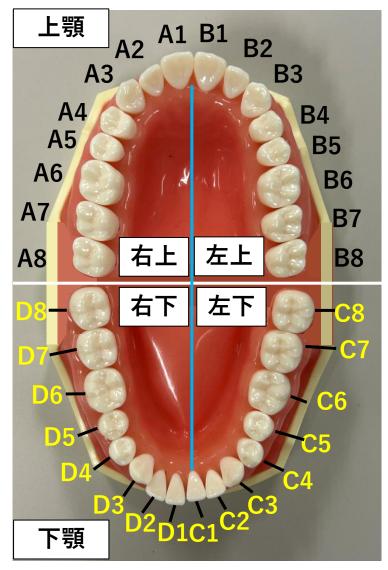
EXCEL ファイル

架空データ

歯の部位

歯の状態

	А	В	С	D	Е
1	id 🔻	tooth name	tooth record	gender 🗸	age 🕝
2	pt_1	A1	残存歯	男	77
3	pt_1	A2	喪失歯	男	77
4	pt_1	А3	残存歯	男	77
5	pt_1	A4	残存歯	男	77
6	pt_1	A5	残存歯	男	77
7	pt_1	A6	残存歯	男	77
8	pt_1	Α7	喪失歯	男	77
9	pt_1	A8	残存歯	男	77
10	pt_1	B1	残存歯	男	77
11	pt_1	B2	喪失歯	男	77
12	pt_1	В3	残存歯	男	77
13	pt_1	В4	残存歯	男	77
14	pt_1	B5	喪失歯	男	77
15	pt_1	В6	残存歯	男	77
16	pt_1	В7	残存歯	男	77
17	pt_1	В8	残存歯	男	77
18	pt_1	C1	残存歯	男	77
19	pt_1	C2	残存歯	男	77
20	pt_1	C3	喪失歯	男	77



患者の歯に関する病院のリアルワールドデータの説明

EXCEL ファイル 架空データ

歯の部位|歯の状態

	А	В	С		D	Е
1	id	tooth name 🖵	tooth record	~	gender 🗸	age 🗸
2	pt_1	A1	残存歯		男	77
3	pt_1	A2	喪失歯		男	77
4	pt_1	А3	残存歯		男	77
5	pt_1	A4	残存歯		男	77
6	pt_1	A5	残存歯		男	77
7	pt_1	A6	残存歯		男	77
8	pt_1	Α7	喪失歯		男	77
9	pt_1	A8	残存歯		上	の部位
10	pt_1	B1	残存歯			
11	pt_1	B2	喪失歯		身	
12	pt_1	B3	残存歯		■ B6	
13	pt_1	B4	残存歯		9 D.7	
14	pt_1	B5	喪失歯		B7	
15	pt_1	B6	残存歯		男	77
16	pt_1	В7	残存歯		男	77
17	pt_1	B8	残存歯		男	77
18	pt_1	C1	残存歯		男	77
19	pt_1	C2	残存歯		男	77
20	pt_1	C3	喪失歯		男	77

残存歯:

口腔内に存在している歯

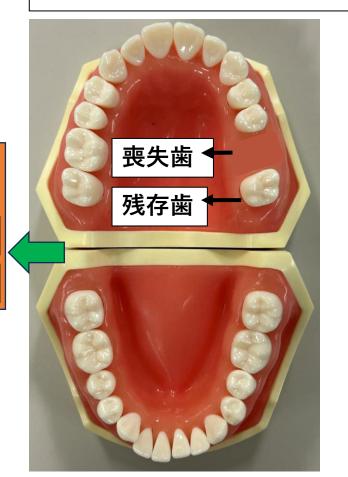
喪失歯:

歯の状態

喪失歯

残存歯

抜歯などによって欠損している歯



患者の歯に関する病院のリアルワールドデータの説明

EXCEL ファイル

架空データ

1	id ↓	tooth name 🖵	tooth record	Ţ	gender 🗸	age 🗸
2	pt_1	A1	残存歯		男	77
3	pt_1	A2	喪失歯		男	77
4	pt_1	А3	残存歯		男	77
5	pt_1	A4	残存歯		男	77
6	pt_1	A5	残存歯		男	77

•	•	•				•	•	•

11419	pt_357	D2	残存歯	女	69
11420	pt_357	D3	残存歯	女	69
11421	pt_357	D4	喪失歯	女	69
11422	pt_357	D5	残存歯	女	69
11423	pt_357	D6	残存歯	女	69

• • •

50636 pt_1583	B3	残存歯	女	40
50637 pt_1583	B4	残存歯	女	40
50638 pt_1583	B5	残存歯	女	40
50639 pt_1583	B6	残存歯	女	40
50640 pt_1583	В7	残存歯	女	40

演習の目標

ID 歯の本数

初診時年齢

• • •

データクレンジング

pt_357 <mark>〇</mark>本

69歳

. . .

pt_1583 <mark>〇</mark>本

40歳



データを可視化する

散布図:年齢と歯の本数

歯の本数

年齡:56

歯の本数:28

年齢:76

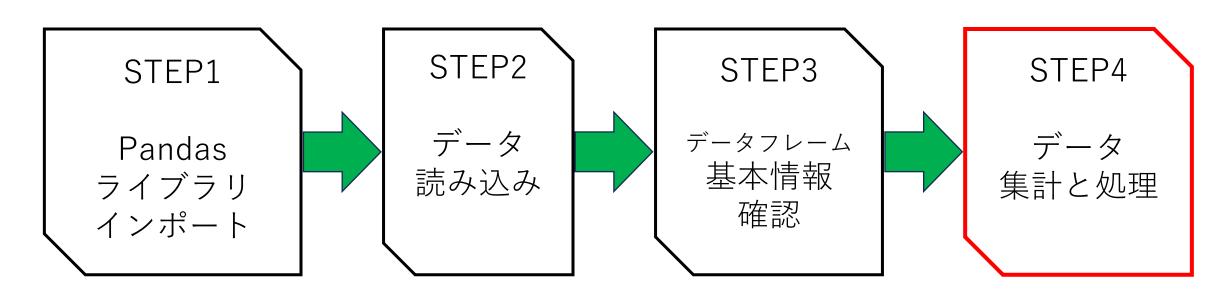
歯の本数:15

Pythonを使用してデータクレンジングを行う必要性

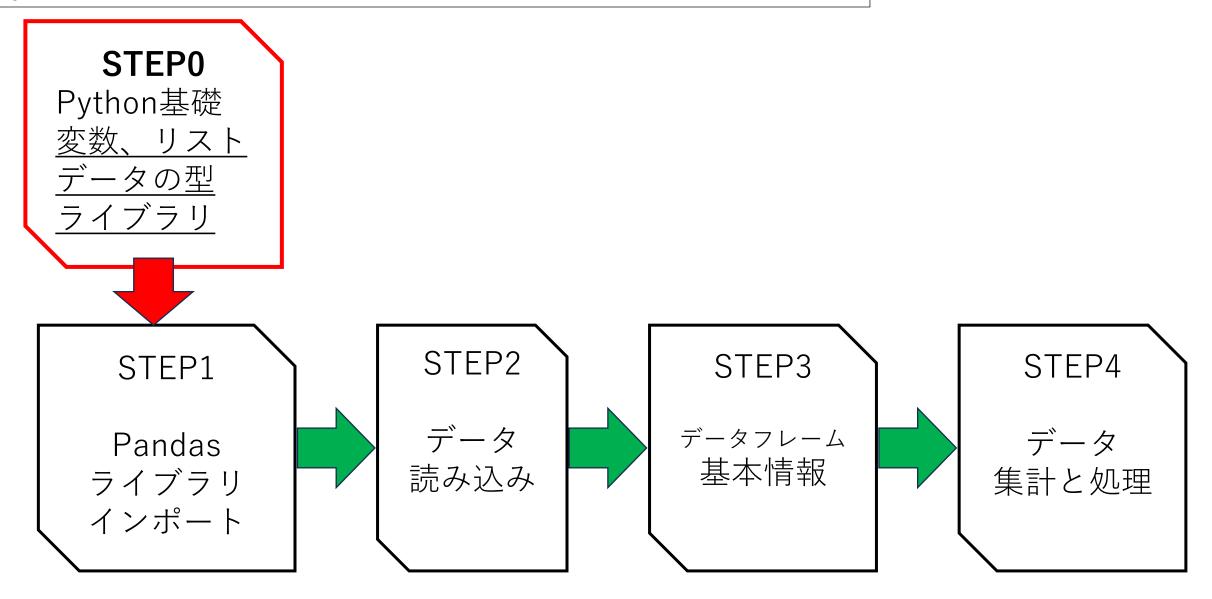
データクレンジングは臨床研究や病院データ管理などの医療領域で非常に重要な手法です。

データクレンジングとは、データセットの特定の問題を修正し、データを分析や機械学習モデルのトレーニングに適した形式に整えるプロセスです。

Pythonを使用してデータクレンジングを行うSTEP



Pythonを使用してデータクレンジングを行うSTEP



Python基礎 Pythonの変数とデータの型

変数とは、データや値を一時的に保持するための名前付きの「箱」のようなものです。 この変数を使用することで、プログラム中でその値を繰り返し利用することができます。

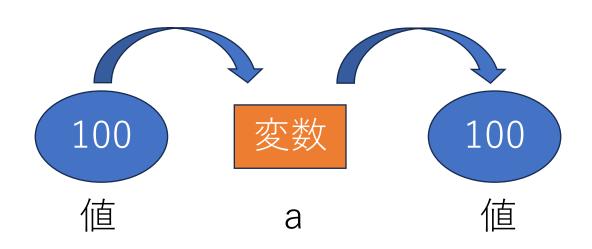
変数に値を代入 変数の値を出力

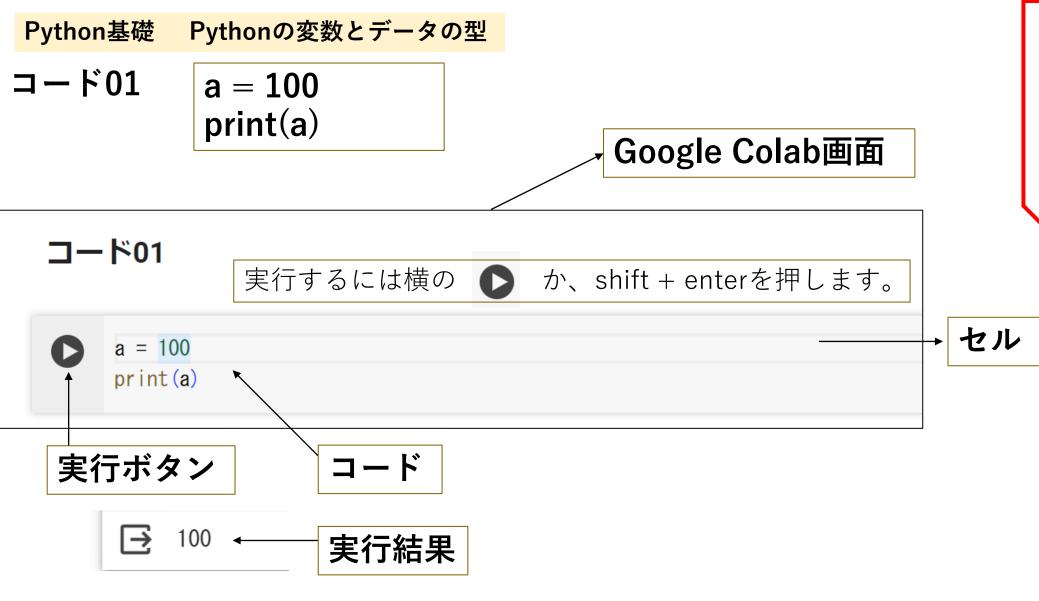
コード01

a = 100

print(a)

プログラミング言語 で表現します





STEP0 Python基礎 変数、リスト データの型

Colab

http://colab.research.google.com

検索google colab <u>Colaboratory へようこそ</u>



11

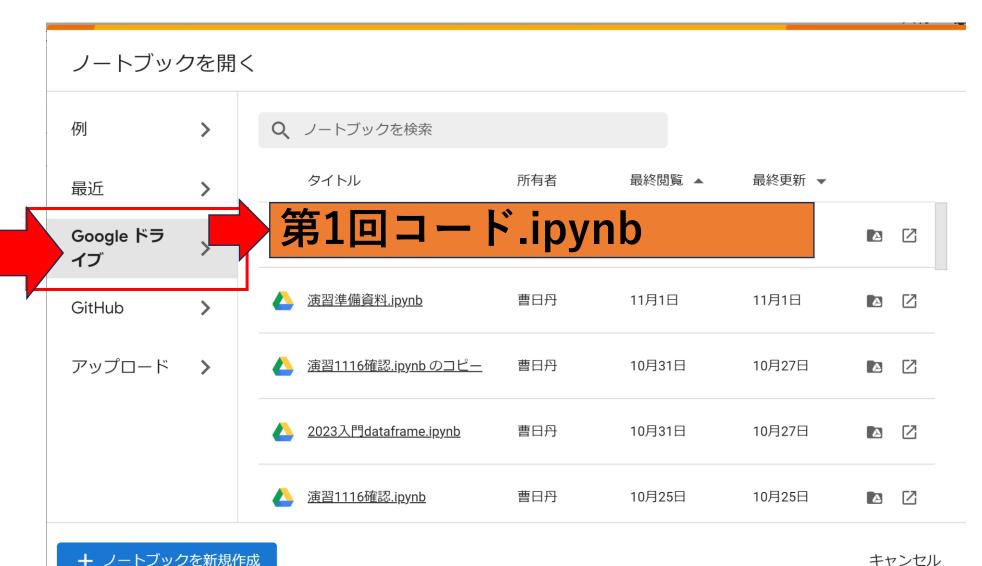
検索google colab

http://colab.research.google.com Colaboratory へようこそ



Colab とは

http://colab.research.google.com 検索google colab Colaboratory へようこそ

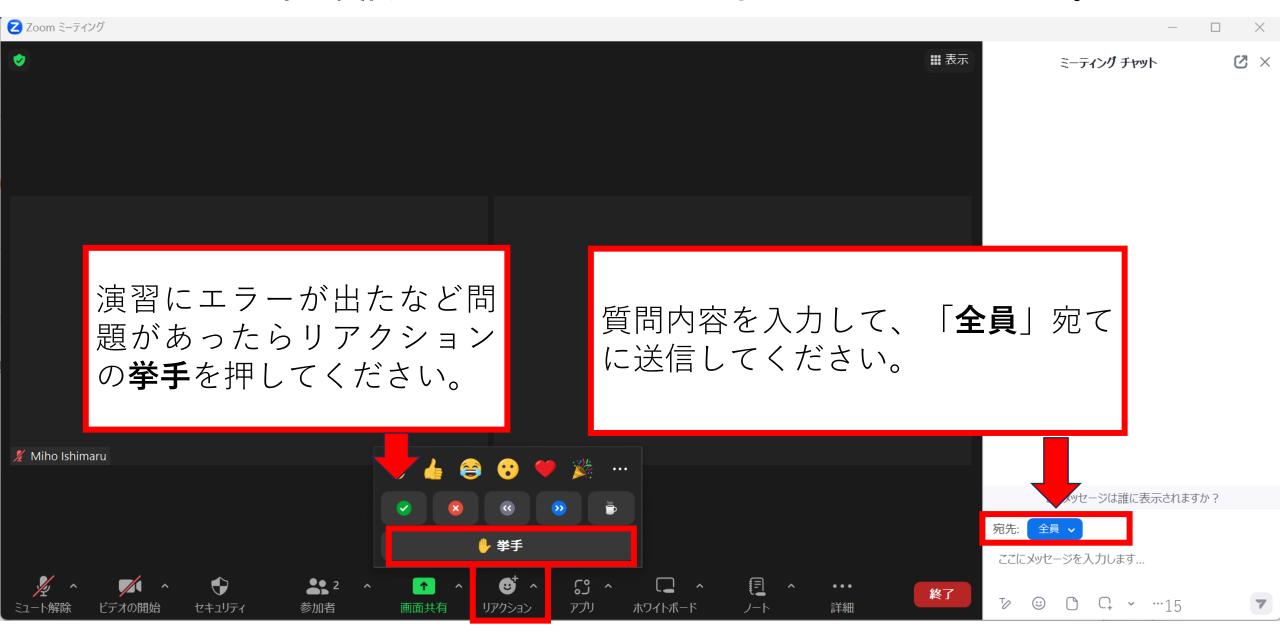


http://colab.research.google.com

検索google colab Colaboratory へようこそ



ワークショップ中の質問をファシリテーターが対応させていただきます。



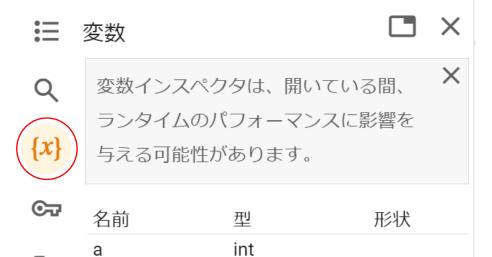
Python基礎 データの型

コード02

$$b = 2.22$$
 小数

$$d = [1, 2, 3, 4, 5]$$
 JXF

変数エクスプローラで型を確認できます



float

str

list

13 chars

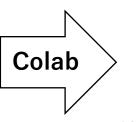
5 items

b

d

STEP0

Python基礎 <u>変数、リスト</u> <u>データの型</u> ライブラリ



Python基礎 Pythonの変数とデータの型

コード03



```
a= 'hello world'
print(a)
```

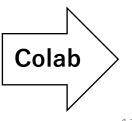
hello world
 [2, 22]

1回目に実行した結果:文字

2回目に実行した結果:リスト

STEP0

Python基礎 <u>変数、リスト</u> <u>データの型</u> ライブラリ



Python基礎

リスト 基本概念と操作

リストとは、順序が付けられた要素の集まりです。 インデックスによって位置を指定して、リストの要素にアクセスできます。

コード04

fruits = ['apple', 'banana', 'cherry', 'melon']

インデックス番号 [0]

[1]

[2]

[3]

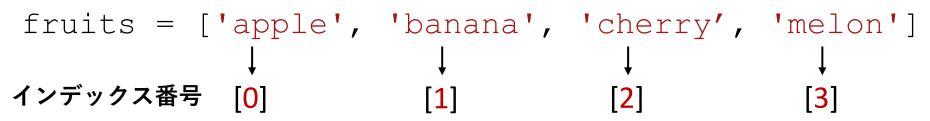
STEP0

Python基礎

Python基礎

リスト 基本概念と操作

コード04



STEP0

Python基礎

インデックス番号を使用して要素にアクセスする

print(fruits[0])

範囲を指定して要素にアクセスする

print(fruits[1:3])

```
Python基礎
        リスト
              基本概念と操作
 コード04
 fruits = ['apple', 'banana', 'cherry', 'melon']
 インデックス番号
             fruits[0]
                        fruits[1]
                                              fruits[3]
                                   fruits[2]
 print(fruits[0])
```

[→] apple

STEP0 Python基礎 変数、リスト データの型 ライブラリ

```
print(fruits[1:3])
[→]['banana', 'cherry']
Colab
```

Python基礎 ライブラリ

Pythonライブラリは、データ分析、機械学習、 データ可視化など、さまざまな高度な機能を提供します。

NumPy:

Pythonで高速な数値計算を行うためのライブラリ。

Pandas:データクレンジングには、Pandasライブラリを使用します。

Pythonでデータ分析を容易にするライブラリで、構造化データの操作や分析を高速かつ効率的に行うためのデータ構造(DataFrame)と関数が提供されています。

Matplotlib:

Pythonでグラフやチャートを描画するためのライブラリ。

Scikit-learn:

Pythonで機械学習を行うためのライブラリで、分類、回帰、クラスタリングなどの機械学習アルゴリズムを簡単に利用できるように設計されています。

STEP0

Python基礎 <u>変数、リスト</u> <u>データの型</u> ライブラリ

Pandas-ライブラリ

Pandasライブラリは、データ分析と操作のための強力なツールを提供しています。 また、データフレーム(DataFrame)というデータ構造を用いて分析できるように なります。

STEP0

Python基礎 変数、リスト データの型 ライブラリ

データフレームとは

表形式のデータを扱うための主要なツールです。

Pandas-ライブラリ

データフレーム

二次元のデータ構造:エクセルのような行と列から成る表形式のデータ構造です。

軸: 各行をインデックス番号で特定します。

各列をその列名で特定します。

STEP0

Python基礎 変数、リスト データの型

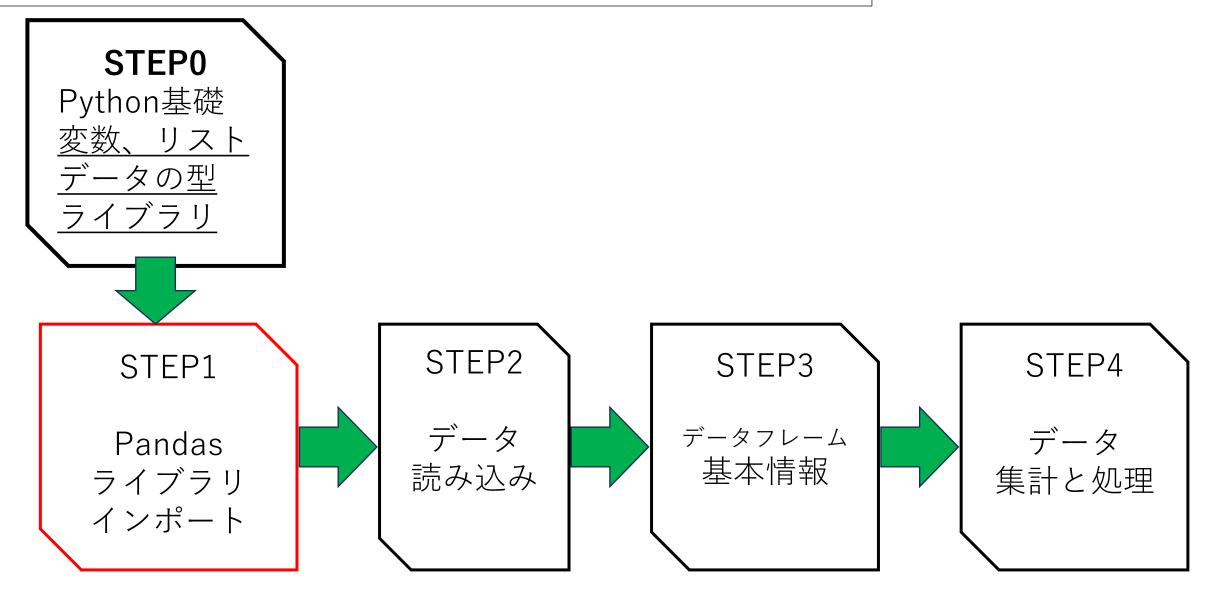
列名

インデックス番号

リストと同様に0 ~n-1のインデッ クス番号が付与さ れています

	ID	名前	年齢	BMI
0	10001	花子	58	26.2
1	10002	太郎	61	20.5
2	10003	良子	70	23.4
3	10004	三郎	92	18.2

Pythonを使用してデータクレンジングを行うSTEP



Pandas ライブラリ インポート Pandas-ライブラリのデータフレーム機能を使うため、Pandasライブラリをインポートする必要があります。

コード05

import pandas as pd

Pandasというライブラリを**pdという略称**でインポートします。 (pdでなくても良いですが、多くの人がpdを使っています。)

データ 読み込み

https://drive.google.com/

Googleアカウントでログインします。



Google

https://drive.google.com > drive > my-drive

https://drive.google.com/

Google ドライブには、Google アカウント(個人ユーザー向け)または Google Workspace アカウント(ビジネス ユーザー向け)でアクセスできます。

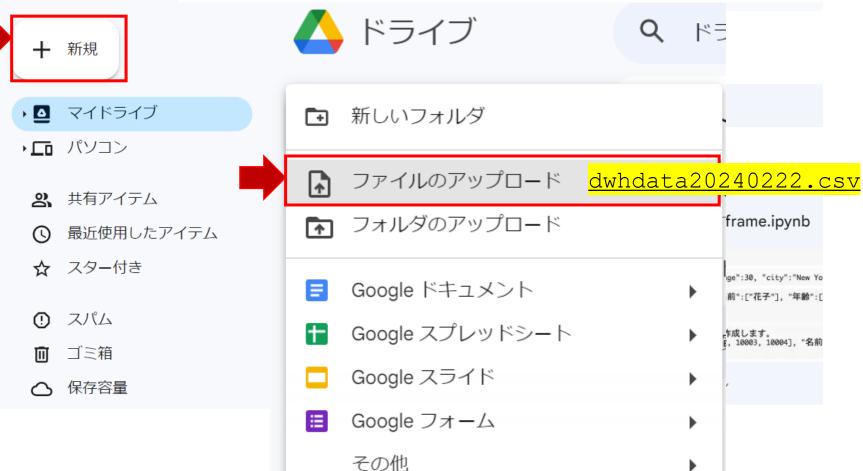


データ 読み込み Google Driveにファイル(<u>dwhdata20240222.csv</u>)をアップロードします



https://drive.google.com/

Googleアカウントでログインします。



コード06

データ 読み込み from google.colab import drive drive.mount('/content/drive')

このノートブックに Google ドライブのファイルへのア クセスを許可しますか?

このノートブックは Google ドライブ ファイルへのアクセスをリクエストしてい ます。Google ドライブへのアクセスを許可すると、ノートブックで実行されたコ ードに対し、Google ドライブ内のファイルの変更を許可することになります。こ のアクセスを許可する前に、ノートブックコードをご確認ください。



Drive already mounted at /content/drive



Google Drive for desktop のプライバシー ポリシーと 利用規約をご覧ください。

プライバシー ポリシーと利用規約をご確認ください。

許可

データ 読み込み Google Colaboratoryでcsvファイルを読み込みます

Pandasライブラリの関数: read csv()

DataFrame名= pd.read_csv('ファイルパス')

コード07

klist = pd.read_csv('/content/drive/My Drive/dwhdata20240222.csv', encoding = 'utf-8')
print(klist)

encoding = 'utf-8'は開く際に文字エンコーディングを指定して文字化けを防ぐために入れています。

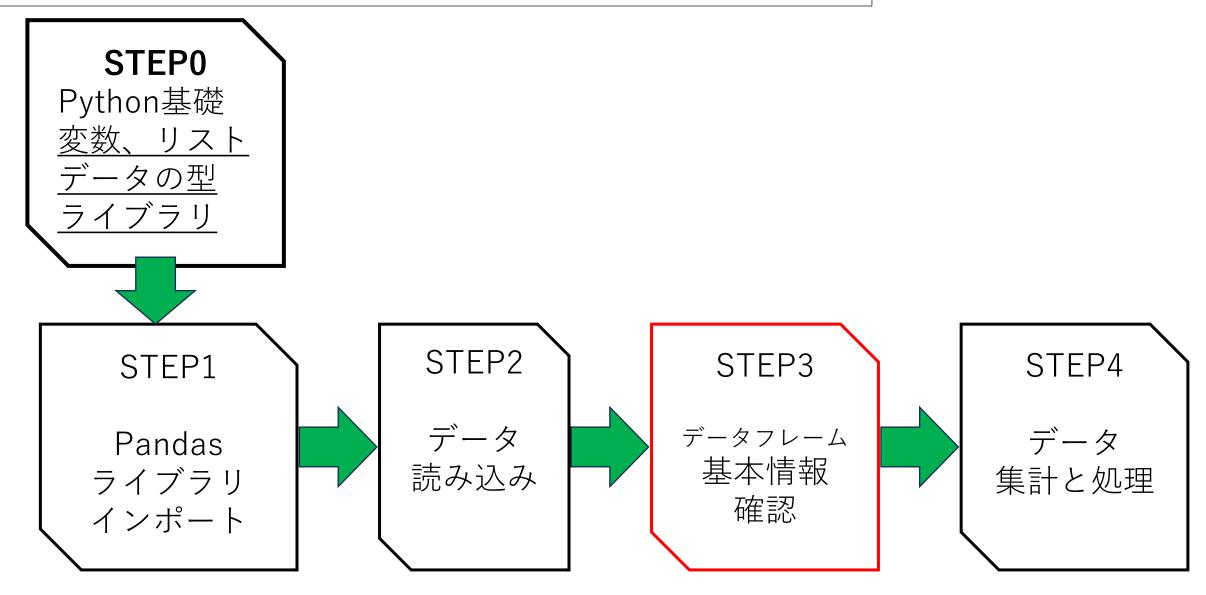
データフレーム読み込み

手順:Google Colaboratoryでcsvファイルを読み込みます

klist = pd.read_csv('/content/drive/My Drive/dwhdata20240222.csv', encoding = 'utf-8')
print(klist)

→		id	tooth name	tooth record ge	nder age	
	0	pt_1	A1	残存歯	_	77
	1	pt_1	A2	喪失歯	男	77
	2	pt_1	A3	残存歯	男	77
	3	pt_1	A4	残存歯	男	77
	4	pt_1	A5	残存歯	男	77
	53019	pt_1657	D4	喪失歯	女	40
	53020	pt_1657	D5	残存歯	女	40
	53021	pt_1657	D6	残存歯	女	40
	53022	pt_1657	D7	喪失歯	女	40
	53023	pt_1657	D8	残存歯	女	40
			_			
	[53024	rows x 5	columns]			

Pythonを使用してデータクレンジングを行うSTEP



STEP3 データフレーム 基本情報

データフレームのshape(行×列)とsize(データ数)を求める

コード08: DataFrame名.shape: DataFrameの形状(行と列の数)を返します。

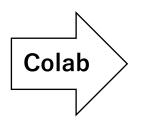
print(klist.shape)

(53024, 5)

コード09: DataFrame名.size: DataFrame内の要素(セル)の総数を返します。

print(klist.size)

265120



STEP3 データフレーム 基本情報

klistデータフレーム

データフレーム内の特定の要素にアクセスする。

tooth record列

Pandasの**locメソッド**(locは、"location"の略です) データフレーム内の特定の位置にアクセスできる。

klist.loc[行のインデックス番号, '列名']

コード10-1

print(klist.loc[0, 'tooth record'])

コード10-2

「:」を使用してtooth record列全ての範囲を取得します。 print(klist.loc[:,'tooth record'])

STEP3 データフレーム 基本情報

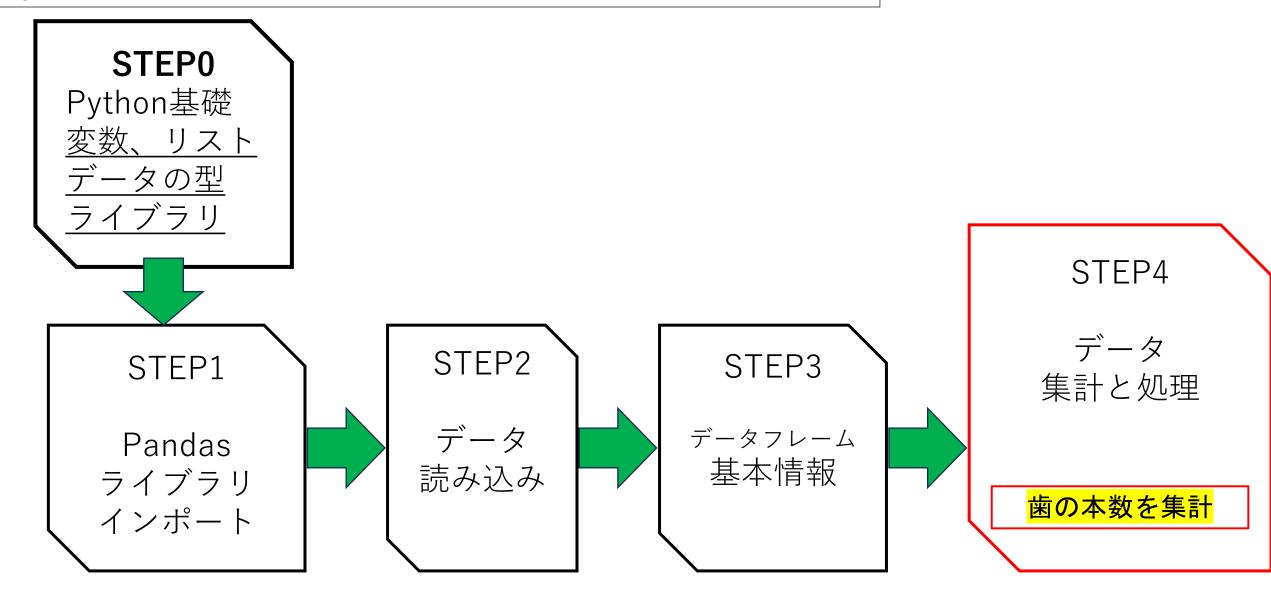
データフレーム内の特定の要素にアクセスする。

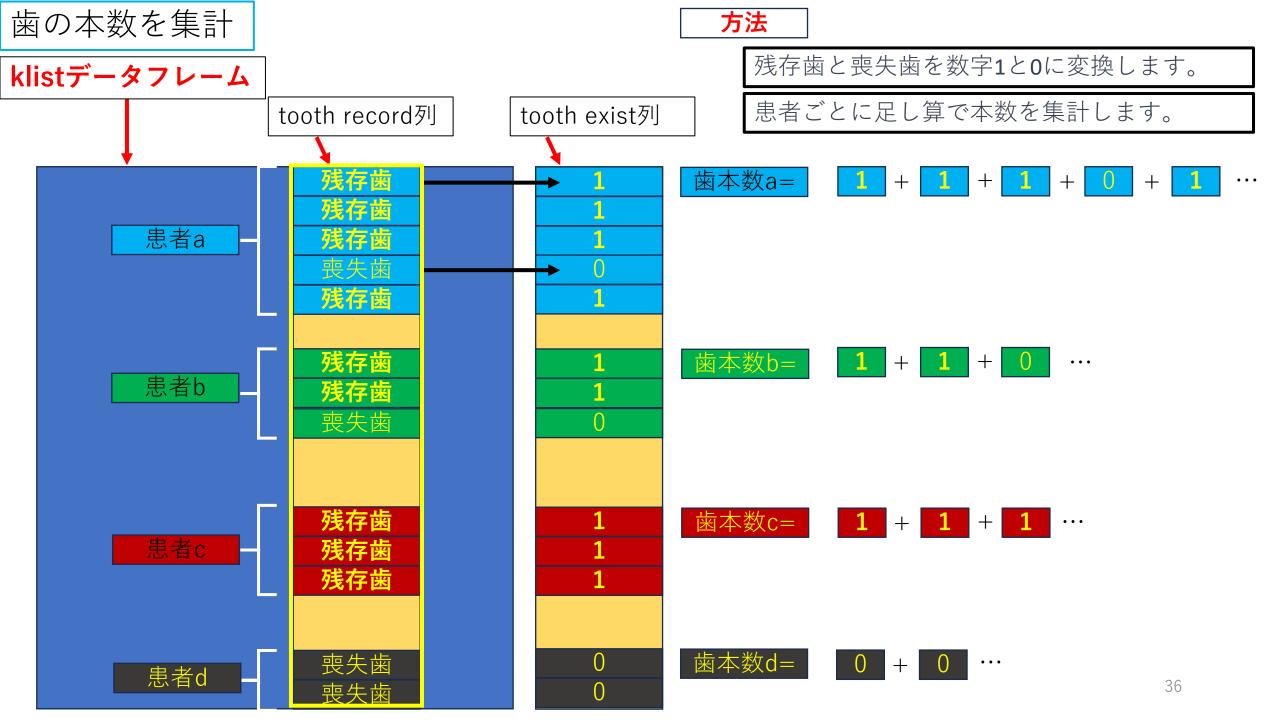
Pandasの<mark>locメソッド</mark>(locは、"location"の略です) tooth record列 データフレーム内の特定の位置にアクセスできる。 klistデータフレーム ☐ ☐ F10-1 | print(klist.loc[0, 'tooth record']) 残存歯 コード10-2 print(klist.loc[:,'tooth record']) 残存歯 喪失歯 残存歯 残存歯 残存歯 喪失歯 53019 53020 残存歯 Colab 残存歯 53021 53022 喪失歯

53023

残存歯

Pythonを使用してデータクレンジングを行うSTEP





klistデータフレーム

tooth record列 tooth exist列 喪失歯 残存歯

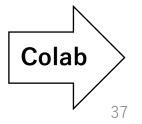
コード11-1

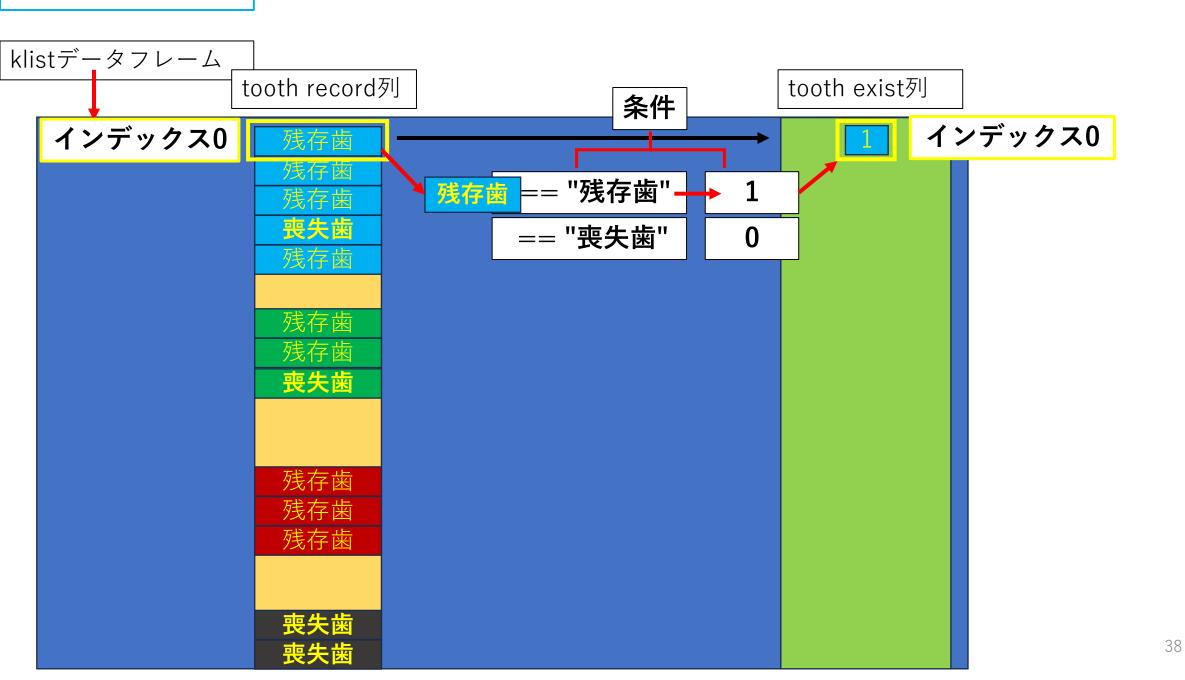
列を追加する

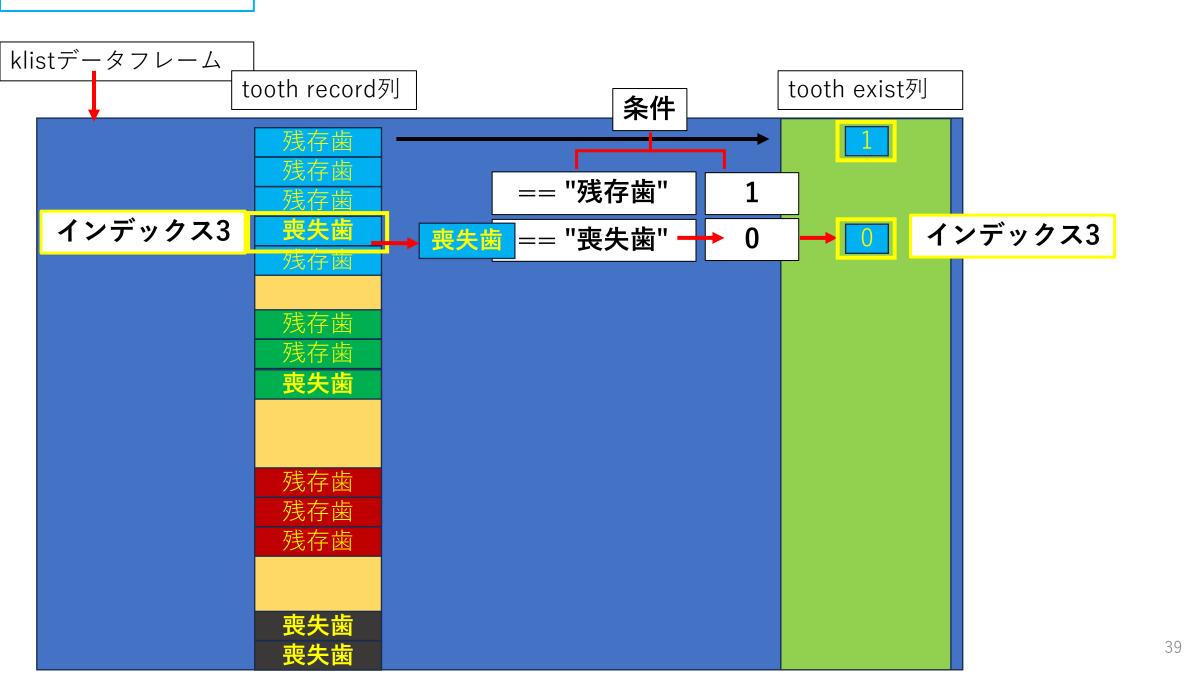
klist['tooth exist'] = None
print(klist)

\supseteq		id	tooth name	tooth	record g	gender	age	tooth	exis.	t
	0	pt_1	A1		残存证	歯	男	77		None
	1	pt_1	A2		喪失ī	蜭	男	77		None
	2	pt_1	A3		残存证	歯	男	77		None
	3	pt_1	A4		残存ī	歯	男	77		None
	4	pt_1	A 5		残存证	歯	男	77		None
	53019	pt_1657	D4		喪失ī	蜭	女	40		None
	53020	pt_1657	D5		残存证	蜭	女	40		None
	53021	pt_1657	D6		残存证	歯	女	40		None
	53022	pt_1657	D7		喪失ī	歯	女	40		None
	53023	pt_1657	D8		残存证	뇌	女	40		None

[53024 rows $x \in 6$ columns]







Python基礎 プログラミング基礎

if

日本語でのif文に相当する部分は「もし~なら」や「もし条件が成り立つ場合は」などのように言えます。

if **条件**:

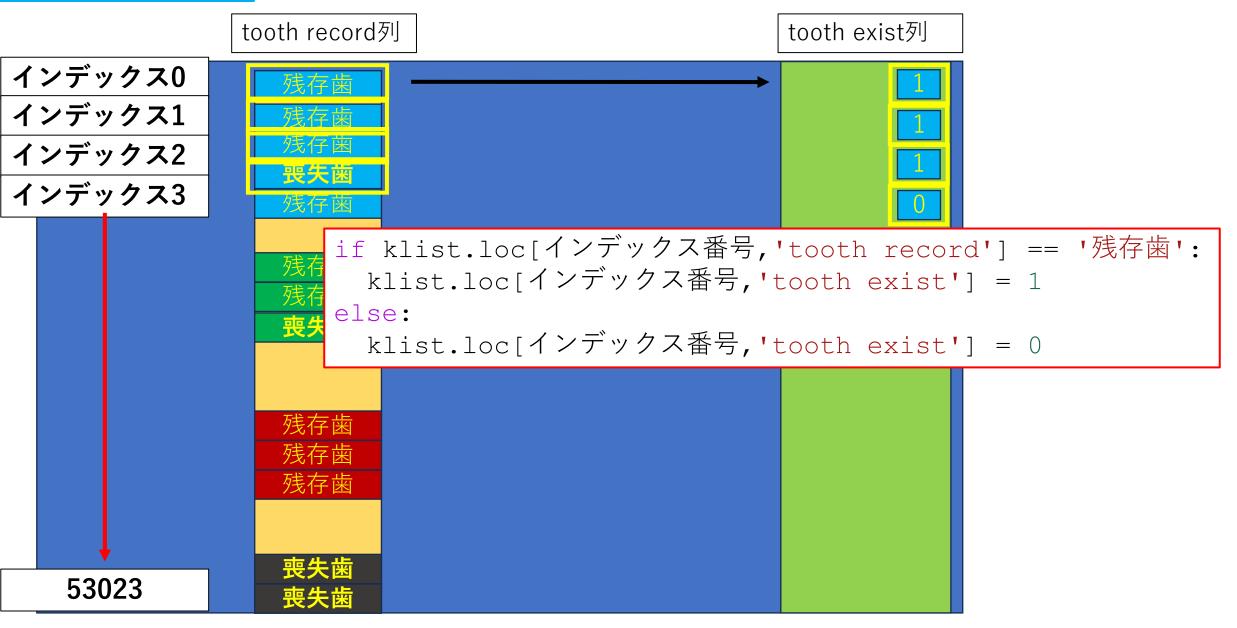
条件が真の場合に実行されるコード

else:

条件が偽の場合に実行されるコード

真(True)か偽(False)

条件が真(True)か偽(False)かを判定するためには、**比較演算子**や**論理演算子**を使用します。



Python基礎 プログラミング基礎

for 日本語でのfor文に相当する部分は「~ごとに繰り返す」などのように言えます。

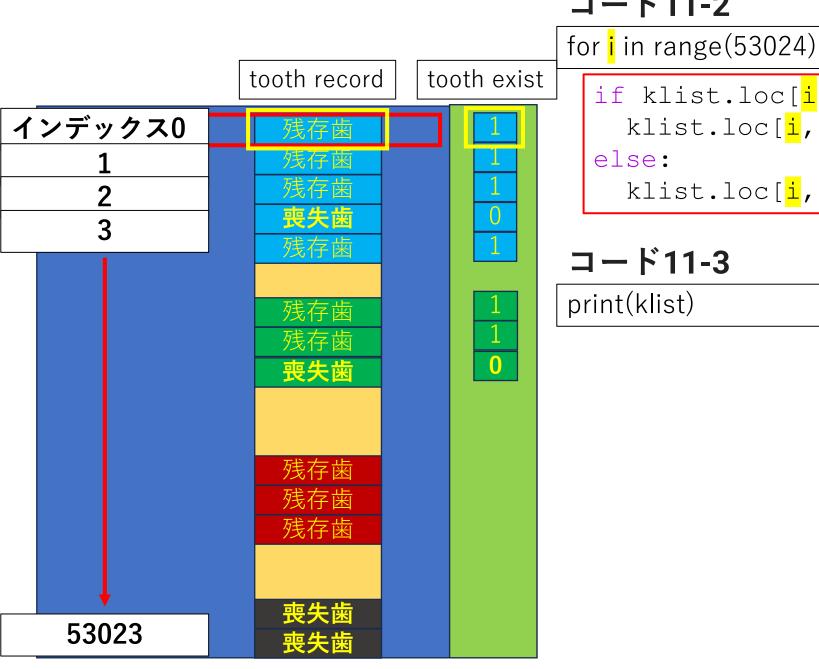
for **変数** in **要素の集まり**:

変数ごとに繰り返す繰り返し実行するコード



for **行インデックス番号** in (**0,1,2…53023**):

```
if klist.loc[インデックス番号,'tooth record'] == '残存歯':
    klist.loc[インデックス番号,'tooth exist'] = 1
else:
    klist.loc[インデックス番号,'tooth exist'] = 0
```



コード11-2

```
if klist.loc[i,'tooth record'] == '残存歯':
 klist.loc[i,'tooth exist'] = 1
else:
 klist.loc[i,'tooth exist'] = 0
```

コード11-3

print(klist)

コード11-3	print(klist)	

	id	tooth name	tooth	rec	ord ger	nder	age	tooth	exist	
0	pt_1	A1			残存歯		男	77		1
1	pt_1	A2			喪失歯		男	77		0
2	pt_1	A3			残存歯		男	77		1
3	pt_1	A4			残存歯		男	77		1
4	pt_1	A5			残存歯		男	77		1
53019	pt_1657	D4			喪失歯		女	40		0
53020	pt_1657	D5			残存歯		女	40		1
53021	pt_1657	D6			残存歯		女	40		1
53022	pt_1657	D7			喪失歯		女	40		0
53023	pt_1657	D8			残存歯		女	40		1

[53024 rows $x \ 6 \ columns$]

患者年齢と歯の本数の関係

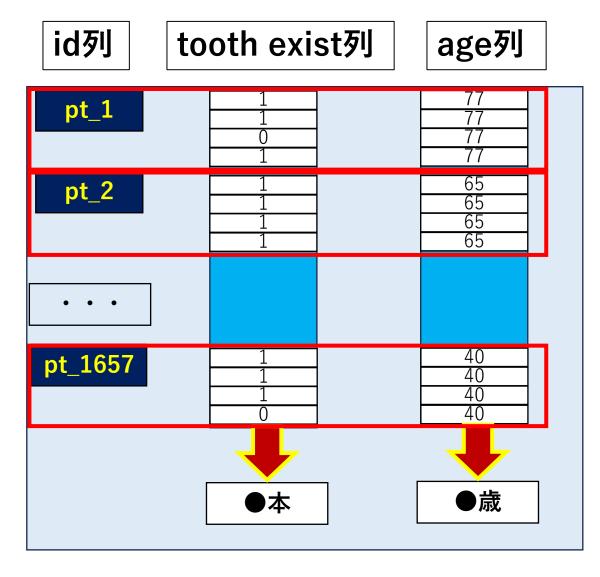
縦軸y: 歯の本数

• 患者pt_1

患者pt_2

横軸x 縦軸y ●歳 ●本 患者pt_1 ●本 患者pt_2 ●歳

横軸x: 患者年齡



Pandasの**groupbyメソッド**は、

列を指定してデータをグループ化し、それぞれの グループに対して集計できます。

列Aでグループ化し、列Bを集計します。 klist.groupby('A')['B'].<mark>集計方法</mark>()

横軸x

年齢の集計

A:id列

B:age列

集計方法:平均值

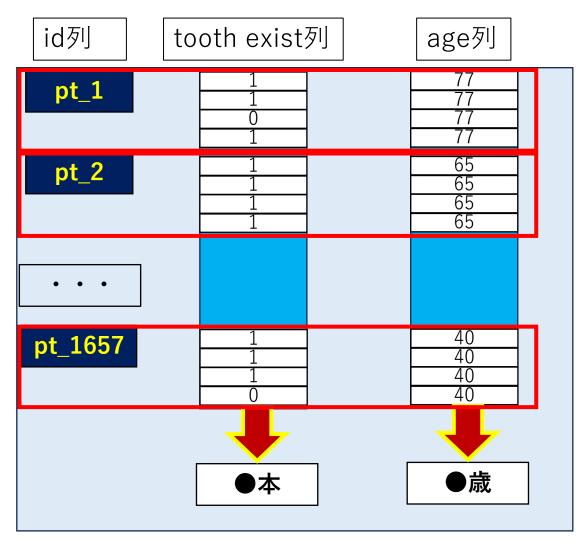
縦軸y

歯の本数の集計

A:id列

B:tooth exist列

集計方法:合計



Pandasの**groupbyメソッド**は、

列を指定してデータをグループ化し、それぞれの グループに対して集計できます。

列Aでグループ化し、列Bを集計します。 klist.groupby('A')['B'].<mark>集計方法</mark>()

横軸x

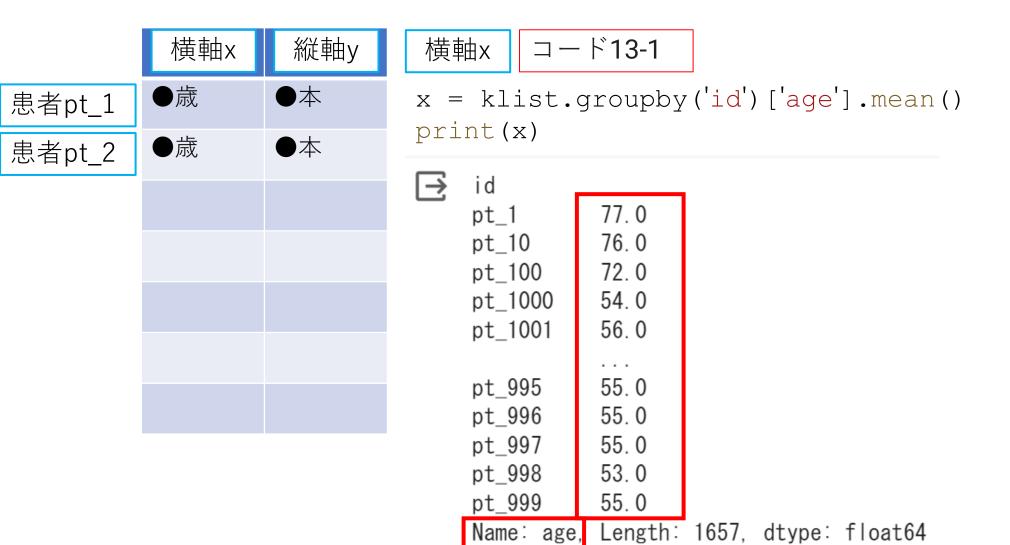
コード13-1

x = klist.groupby('id')['age'].mean() print(x)

縦軸y

コード13-2

y = klist.groupby('id')['tooth exist'].sum() print(y)

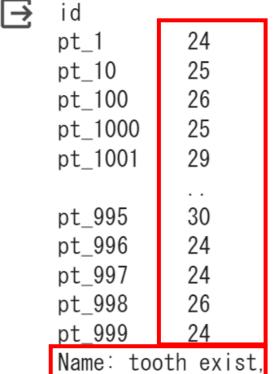




縦軸y

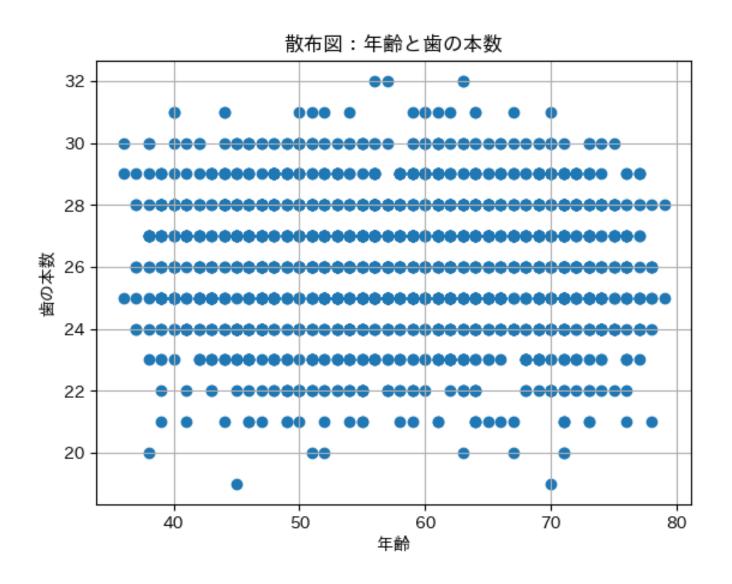
コード13-2

```
y = klist.groupby('id')['tooth exist'].sum()
print(y)
```



Length: 1657, dtype: object

```
コード13-3
            import numpy as np
           x = np.array(x)
            y = np.array(y)
            matplotlibライブラリと日本語入力方法をインポートします。
コード13-4
            import matplotlib.pyplot as plt
            !pip install japanize-matplotlib
            import japanize matplotlib
            matplotlibライブラリで散布図を作成します。
コード13-5
           plt.figure()
           plt.title('散布図:年齢と歯の本数')
           plt.xlabel('年龄')
           plt.ylabel('歯の本数')
           plt.grid()
           plt.scatter(x,y)
           plt.show()
```



WS2回目の事前準備のご案内

WS2回目では画像データを使うため、事前準備のご協力をお願いします

①webclassにログインし、IL2300919 医療系データサイエンス教育ワークショップ 2023年度版 のコースにアクセスしてください。「2回目の事前準備」をクリックしてください。



事前準備

② 第1章 「WS2回目_事前準備」に内容が書かれていますので、この通りに 準備をお願いします



ご清聴をありがとうございます。

アンケートのご協力をお願いいたします。



Webclass QR⊐−F

IL2300919 医療系データサイエンス教育ワークショップ 2023年度版

第1回演習後アンケート

2月22日演習後に回答お願いします。

全体演習後アンケート

最終回までにご回答をお願いします。